

**Instituto tecnológico de Culiacán**  
**Ingeniería en tecnologías de la información y comunicaciones**  
**Tópicos de Inteligencia Artificial**

**“Inteligencia artificial y machine learning aplicada en la  
agricultura sostenible”**

Barraza Castro Jesús Alberto

Wong Camacho Jesús Guadalupe

# ÍNDICE

ÍNDICE.....	2
<b>DESCRIPCIÓN.....</b>	<b>4</b>
<b>RESUMEN.....</b>	<b>4</b>
<b>INTRODUCCIÓN.....</b>	<b>4</b>
ANTECEDENTES.....	5
JUSTIFICACIÓN.....	6
OBJETIVO GENERAL Y ESPECÍFICOS.....	7
Objetivo General:.....	7
Objetivos Específicos:.....	8
<b>METAS.....</b>	<b>9</b>
<b>Impacto o beneficio en la solución a un problema relacionado con el sector productivo o la generación del conocimiento científico o tecnológico.....</b>	<b>10</b>
<b>MARCO TEÓRICO.....</b>	<b>11</b>
El uso del Machine Learning, Big Data e IA en la agricultura.....	11
Machine Learning.....	11
Big Data.....	12
Inteligencia Artificial.....	12
Beneficios del uso de aprendizaje automático, Big Data e IA en la agricultura.....	12
Desafíos del uso de aprendizaje automático, Big Data e IA en la agricultura.....	13
Predicción de rendimientos:.....	14
Detección de plagas y enfermedades:.....	15
Optimización del riego:.....	15
Análisis de suelos:.....	15
Monitoreo del crecimiento de los cultivos:.....	15
Aumento de la productividad:.....	16
Reducción de costos:.....	16
Manejo de malezas:.....	19
Mejora en la cadena de suministro:.....	20
Adaptación al cambio climático:.....	20
Automatización de maquinaria agrícola:.....	21
Predicción de calidad de cultivos:.....	21
Detección de estrés hídrico:.....	21
Desarrollo de nuevas variedades de cultivos:.....	22
<b>METODOLOGÍA.....</b>	<b>22</b>
Fase 1. Recolección y Procesamiento de Datos.....	22
Fase 2. Desarrollo e Implementación de Modelos de IA y Machine Learning.....	23
Fase 3. Validación y Optimización.....	23
<b>PROGRAMA DE ACTIVIDADES Y CALENDARIZACIÓN.....</b>	<b>23</b>
<b>VINCULACIÓN.....</b>	<b>24</b>
<b>REFERENCIAS.....</b>	<b>25</b>



## **DESCRIPCIÓN**

Este protocolo de investigación analiza la integración de Machine Learning, Big Data e Inteligencia Artificial en la agricultura mexicana, con un enfoque en cultivos clave como el tomate y el maíz en Culiacán, Sinaloa. Se explora el estado actual, los desafíos y las oportunidades de estas tecnologías para mejorar la eficiencia, sostenibilidad y productividad agrícola.

## **RESUMEN**

La agricultura en México enfrenta el reto de adaptarse a las nuevas tecnologías de la información para seguir siendo competitiva. Este estudio examina el impacto del Machine Learning, Big Data e Inteligencia Artificial en la optimización de cultivos, gestión de recursos y prevención de plagas. A través de una revisión del estado del arte y casos de aplicación, se busca proporcionar un panorama sobre el potencial y las barreras para la adopción de estas herramientas en el sector agrícola mexicano.

## **INTRODUCCIÓN**

En la era digital, la agricultura enfrenta un periodo de transformación profunda impulsada por la adopción de tecnologías avanzadas. México, reconocido globalmente por su agricultura, se encuentra en una encrucijada: adaptarse a las nuevas tecnologías de la información o arriesgarse a quedar rezagado en un mercado cada vez más competitivo. La integración de Machine Learning (ML), Big Data e Inteligencia Artificial (IA) en la agricultura no solo promete mejorar la eficiencia y productividad, sino también enfrentar desafíos críticos como el cambio climático, la escasez de recursos y la demanda creciente de alimentos. Estas tecnologías tienen el potencial de revolucionar la manera en que se gestionan los cultivos, optimizando el uso de insumos, mejorando la predicción de cosechas y gestionando plagas y enfermedades de manera más efectiva. Sin embargo, a pesar de su potencial, la investigación y aplicación de estas tecnologías en el contexto agrícola mexicano es todavía limitada. Este estudio busca evaluar el estado actual, desafíos y perspectivas futuras del uso de ML, Big Data e IA en la agricultura en

México, con un enfoque especial en cultivos clave como el tomate y el maíz en Culiacán, Sinaloa, para así promover una producción agrícola más sostenible y eficiente.

## **ANTECEDENTES**

México, es uno de los países con menor investigación en esta área, lo cual resulta sorprendente, ya que México es uno de los principales referentes a nivel mundial en cuanto a agricultura. Hoy en día ya es indispensable la integración de sistemas de tecnologías de la información en la agricultura, al ser una de las prácticas indispensables para la humanidad, estos sistemas generan una cantidad de datos enorme, llegando a considerarse dentro del ámbito del "big data". Esto implica un reto muy grande que es el almacenamiento de esta información, al ser de tal volumen, resulta muy costoso almacenar y mantener esta información. (Benos et al, 2021)

Para analizar los datos que se generan en la agricultura, se utilizan bases de datos y algoritmos de inteligencia artificial, específicamente de aprendizaje automático, para evaluar las interacciones complejas entre factores como el clima, el suelo, las prácticas de manejo y las variedades de semillas. Estos algoritmos pueden identificar sistemas de cultivo con alto potencial de rendimiento en entornos específicos, acelerando la investigación agrícola y ayudando a satisfacer la demanda alimentaria futura. (Mourtzinis et al, 2021)

India es uno de los países donde la agricultura es una industria principal ya que esta aporta con el 19.9% del producto interno bruto. La agricultura y actividades afines involucran casi al 45% de la población del país. (Singh, A., 2019)

El Big Data no funciona de manera aislada. Ha sido utilizado con otras tecnologías como ML, plataformas basadas en la nube, procesamiento de imágenes, modelado y simulación, análisis estadístico, índices de vegetación NDVI y sistemas de información geográfica (GIS). (Cravero, A. et al, 2022)

Como se puede observar, la mayor parte, que representa el 74.6%, está dedicada a la gestión de cultivos. El dominio de gestión del agua representa el 21.7%, seguido por los dominios de gestión del suelo y gestión de animales, con un 16.5% y un 12.5%, respectivamente. El porcentaje total de cada dominio representa la proporción de artículos que se centran principalmente en ese dominio específico. Sin embargo, ciertos artículos pueden ser multidisciplinarios en su naturaleza, abordando más de un dominio dentro del contexto agrícola. Además, se delinearon cinco subdominios, representando un área de enfoque distinta dentro del dominio de cultivos: calidad del cultivo (33.8%), mapeo/reconocimiento de cultivos (27.9%), rendimiento del cultivo (20.6%), enfermedades del cultivo (8.8%) y detección de plagas/malezas (1.8%). (Araújo, S. et al, 2023)

El objetivo de producción global de alimentos se estima que aumentará entre un 6 y un 10% para el año 2050 (Krishna, 2016) para alimentar a la creciente población. Se espera que este aumento en la demanda provoque escasez de alimentos. Además, debido a la aparición de varios escándalos e incidentes de seguridad alimentaria en el sector alimentario, como la encefalopatía espongiforme bovina y el dioxin en aves de corral (Ben-Ayed, Kamoun-Grati y Rebai, 2013), se requiere un sistema de trazabilidad integral en la cadena alimentaria. (Ben-Ayed, H. et al, 2013).

## **JUSTIFICACIÓN**

El uso de pronósticos de machine learning en la agricultura puede tener un impacto significativo en los cultivos de frutas y verduras, así como en todo el sistema de cultivo. Aquí te presento algunas justificaciones claras de este impacto: Optimización de la producción: Los pronósticos de machine learning pueden analizar grandes cantidades de datos históricos, como condiciones climáticas, tipos de suelo, patrones de siembra y cosecha, para predecir con precisión la producción futura de cultivos. Esto permite a los agricultores planificar de manera más eficiente sus operaciones, optimizando la cantidad de productos cultivados para satisfacer la demanda del mercado. Reducción de pérdidas: Al prever las condiciones climáticas adversas u

otros eventos que podrían afectar los cultivos, los agricultores pueden tomar medidas preventivas para minimizar las pérdidas. Por ejemplo, si se pronostica una tormenta, pueden cosechar los cultivos antes de que sean dañados por la lluvia o el viento, lo que reduce la cantidad de productos perdidos. Mejora de la calidad del producto: Al utilizar algoritmos de machine learning para analizar datos sobre las prácticas agrícolas, como el riego, la fertilización y el control de plagas, los agricultores pueden optimizar estas actividades para mejorar la calidad de los cultivos. Esto puede resultar en productos más sanos, más sabrosos y atractivos para los consumidores. Ahorro de recursos: Los pronósticos precisos pueden ayudar a los agricultores a utilizar los recursos de manera más eficiente. Por ejemplo, al prever la demanda de agua de los cultivos en función de las condiciones climáticas, pueden programar el riego de manera óptima para minimizar el desperdicio de agua y reducir los costos operativos. Sostenibilidad ambiental: Al optimizar el uso de recursos como el agua y los fertilizantes, y al reducir las pérdidas de cultivos, el uso de pronósticos de machine learning puede contribuir a una agricultura más sostenible y respetuosa con el medio ambiente. Esto es especialmente importante dado el creciente énfasis en la agricultura sostenible y la conservación de recursos naturales. En conclusión, el uso de pronósticos de machine learning en la agricultura puede mejorar la eficiencia, la productividad y la sostenibilidad de los cultivos de frutas y verduras, beneficiando tanto a los agricultores como a los consumidores.

## **OBJETIVO GENERAL Y ESPECÍFICOS**

### **Objetivo General:**

Evaluar el estado actual y las tendencias emergentes del uso de algoritmos de aprendizaje automático en la agricultura, así como identificar los desafíos y perspectivas futuras en la integración de estos sistemas en la gestión agrícola.

## **Objetivos Específicos:**

### Revisión de la Literatura:

Realizar una revisión exhaustiva de la literatura existente sobre la aplicación del aprendizaje automático en la agricultura, incluyendo las revisiones comprensivas de Benos et al. (2021) y Cravero et al. (2022), para identificar las áreas de aplicación más comunes y los avances recientes en este campo.

### Evaluación de Herramientas y Métodos:

Analizar los distintos algoritmos de aprendizaje automático y sus aplicaciones específicas en la agricultura, como se detalla en los estudios de Mourtzinis et al. (2021b) y Araújo et al. (2023), para determinar su efectividad y eficiencia en diferentes contextos agrícolas.

### Impacto del Big Data:

Investigar el papel del big data en la investigación y desarrollo agrícola, basándose en el trabajo de Singh (2019), para comprender cómo la gran cantidad de datos generados puede ser aprovechada mediante técnicas de aprendizaje automático para mejorar la toma de decisiones y la productividad agrícola.

### Desafíos y Limitaciones:

Identificar los principales desafíos y limitaciones en la implementación del aprendizaje automático en la agricultura, como se presenta en Cravero et al. (2022) y Araújo et al. (2023), incluyendo cuestiones técnicas, económicas y éticas.

### Perspectivas Futuras:

Explorar las futuras direcciones y potenciales innovaciones en el uso de aprendizaje automático en la agricultura, basándose en la revisión de Araújo et al. (2023), para ofrecer una visión prospectiva que pueda guiar futuras investigaciones y desarrollos tecnológicos en este campo.



## Seguridad Alimentaria y Trazabilidad:

Evaluar cómo el aprendizaje automático puede contribuir a mejorar la seguridad alimentaria y la trazabilidad de los alimentos, haciendo referencia al estudio de Ben-Ayed et al. (2013), para desarrollar sistemas más seguros y eficientes en la cadena de suministro agrícola.

Al abordar estos objetivos, se espera proporcionar una comprensión profunda y actualizada del uso del aprendizaje automático en la agricultura, así como identificar áreas clave para la mejora y futuras investigaciones.

## **METAS**

Las metas de este estudio se centran en la integración de tecnologías avanzadas como el aprendizaje automático (Machine Learning), Big Data e Inteligencia Artificial (IA) en la agricultura mexicana, con un enfoque particular en los cultivos de tomate y maíz en Culiacán, Sinaloa. A través de este análisis, se busca aportar información relevante que impulse el desarrollo de estrategias innovadoras y sostenibles en el sector agrícola.

- Comprender el estado actual de la tecnología en la agricultura mexicana
- Evaluar el nivel de adopción de herramientas de Machine Learning, Big Data e IA en los procesos agrícolas.
- Analizar las tendencias emergentes en la digitalización del sector agrícola.
- Optimizar la producción agrícola mediante la tecnología
- Identificar cómo el uso de modelos predictivos puede mejorar los rendimientos de los cultivos.
- Explorar cómo la automatización y el análisis de datos pueden reducir costos y aumentar la productividad.
- Identificar los desafíos en la implementación de la tecnología
- Analizar las barreras económicas, técnicas y sociales que dificultan la adopción de estas herramientas.

- Evaluar el impacto de la falta de infraestructura tecnológica en el desarrollo agrícola.
- Promover prácticas agrícolas sostenibles
- Determinar cómo la aplicación de Big Data y Machine Learning puede optimizar el uso de agua, fertilizantes y pesticidas.
- Explorar soluciones tecnológicas para enfrentar problemas como el cambio climático y la escasez de recursos naturales.
- Fortalecer la seguridad alimentaria y la trazabilidad en la cadena de suministro

### **Impacto o beneficio en la solución a un problema relacionado con el sector productivo o la generación del conocimiento científico o tecnológico**

Desde una perspectiva científica y tecnológica, este proyecto contribuye al desarrollo de modelos de predicción avanzados que pueden ser adaptados a distintas regiones y tipos de cultivos. La implementación de estas tecnologías no solo impulsa la digitalización del sector agrícola, sino que también fomenta la investigación en áreas como el procesamiento de datos agroclimáticos, visión por computadora aplicada a la agricultura y optimización de redes neuronales para la toma de decisiones en entornos naturales.

Además, al promover prácticas agrícolas sostenibles, este enfoque ayuda a reducir el impacto ambiental de la producción agrícola, minimizando el desperdicio de recursos y mejorando la resiliencia de los sistemas de cultivo frente al cambio climático. Esto abre nuevas oportunidades para la colaboración entre instituciones académicas, el sector agrícola y empresas tecnológicas, consolidando un ecosistema de innovación en la agricultura de precisión.

## MARCO TEÓRICO

### El uso del Machine Learning, Big Data e IA en la agricultura

El sector agrícola se enfrenta a numerosos desafíos, como el **cambio climático**, la **escasez** de recursos y la **creciente demanda de alimentos**. Para abordar estos desafíos, la industria agrícola está recurriendo cada vez más a las tecnologías emergentes como el **Machine Learning, Big Data e Inteligencia Artificial (IA)**. Estas tecnologías tienen el potencial de **revolucionar** la agricultura al mejorar la **productividad**, la **eficiencia** y la **sostenibilidad**.

#### Machine Learning

El Machine Learning es una rama de la **IA** que permite a los sistemas informáticos aprender sin ser programados explícitamente. En el contexto de la agricultura, el aprendizaje automático se puede utilizar para una amplia gama de tareas, como:

- **Análisis de imágenes** para identificar plagas, enfermedades y malezas.
- **Monitoreo del rendimiento** de los cultivos para detectar problemas potenciales y optimizar las prácticas de gestión.
- **Predicción del clima** y las condiciones del suelo para ayudar a los agricultores a tomar mejores decisiones sobre la siembra, el riego y la fertilización.
- **Automatización de tareas** como la clasificación de frutas y verduras y el ordeño de ganado.

## Big Data

Big Data se refiere a grandes conjuntos de datos que son demasiado voluminosos, complejos y rápidos para ser procesados por métodos tradicionales. En la agricultura, Big Data se genera a partir de una variedad de fuentes, como sensores en campos y maquinaria agrícola, imágenes satelitales y redes sociales. Estos datos se pueden utilizar para obtener información sobre el rendimiento de los cultivos, la salud del suelo, el comportamiento animal y las tendencias del mercado.

## Inteligencia Artificial

La IA es una rama de la informática que se ocupa de la creación de agentes inteligentes, que son sistemas que pueden razonar, aprender y actuar de forma autónoma. En la agricultura, la IA se puede utilizar para desarrollar sistemas de apoyo a la decisión que ayudan a los agricultores a tomar mejores decisiones sobre la gestión de sus cultivos y ganado. La IA también se puede utilizar para automatizar tareas complejas, como la planificación de la siembra y la cosecha.

## Beneficios del uso de aprendizaje automático, Big Data e IA en la agricultura

El uso de aprendizaje automático, Big Data e IA en la agricultura puede ofrecer una serie de beneficios, que incluyen:

- **Mayor productividad:** Estas tecnologías pueden ayudar a los agricultores a aumentar sus rendimientos y producir más alimentos con menos recursos.
- **Mayor eficiencia:** La automatización de tareas y la optimización de procesos pueden ayudar a los agricultores a ahorrar tiempo y dinero.
- **Mayor sostenibilidad:** Estas tecnologías pueden ayudar a los agricultores a reducir su impacto ambiental al optimizar el uso de agua, fertilizantes y pesticidas.

- **Mejor toma de decisiones:** El análisis de Big Data puede proporcionar a los agricultores información valiosa que puede ayudarlos a tomar mejores decisiones sobre la gestión de sus cultivos y ganado.

## **Desafíos del uso de aprendizaje automático, Big Data e IA en la agricultura**

A pesar de los muchos beneficios potenciales, existen algunos desafíos asociados con el uso de aprendizaje automático, Big Data e IA en la agricultura. Estos desafíos incluyen:

- **Costo:** La implementación de estas tecnologías puede ser costosa, lo que puede dificultar su acceso a los pequeños agricultores.
- **Datos:** Se necesitan grandes cantidades de datos de alta calidad para entrenar modelos de aprendizaje automático. Estos datos pueden ser costosos de recopilar y limpiar.
- **Habilidades:** Se necesitan trabajadores calificados para desarrollar, implementar y mantener estas tecnologías.
- **Aceptación:** Algunos agricultores pueden ser reacios a adoptar estas nuevas tecnologías debido a preocupaciones sobre el costo, la complejidad o los posibles impactos en el empleo.

En 2023 mas de 100 millones de usuarios utilizaron estas tecnologías, por lo cual se puede inferir que en unos años estas tecnologías serán requeridas en varias áreas de desarrollo humano, siendo una de ellas la agricultura Anexo A Cronograma.

México es uno de los principales productores de tomate y maíz a nivel mundial. Sin embargo, la productividad de estos cultivos se ve afectada por diversos factores, como las plagas, las enfermedades, las condiciones climáticas adversas y las prácticas agrícolas inadecuadas. En este contexto, el machine learning y la ciencia

de datos se presentan como herramientas prometedoras para mejorar la eficiencia y la sostenibilidad de la agricultura mexicana. (Benos, L. et al, 2021).

México, es uno de los países con menor investigación en esta área, lo cual resulta sorprendente, ya que México es uno de los principales referentes a nivel mundial en cuanto a agricultura, como se muestra en la Figura 1.

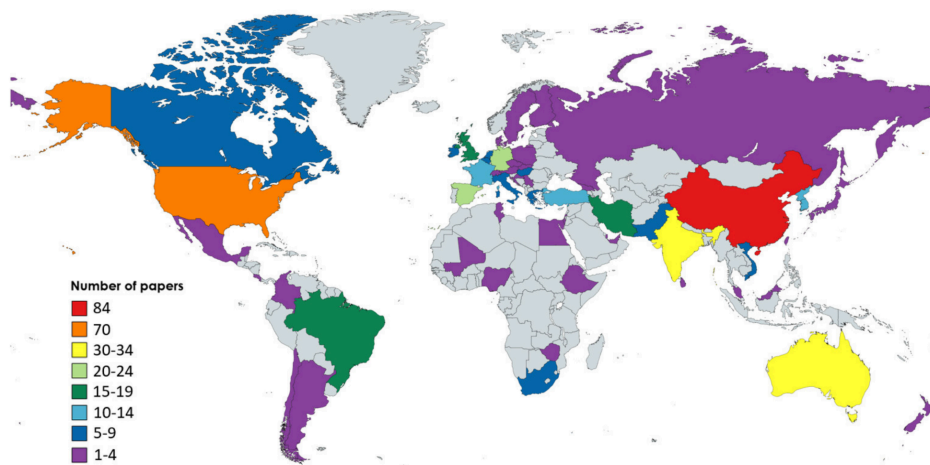


Fig.1 - Distribución geográfica de la contribución de cada país al campo de investigación centrado en el aprendizaje automático en agricultura (Benos, L. et al, 2021).

El machine learning y la ciencia de datos pueden ser utilizados para una amplia gama de aplicaciones en la agricultura del tomate y maíz, incluyendo:

### **Predicción de rendimientos:**

Los algoritmos de machine learning pueden ser entrenados para predecir los rendimientos de los cultivos en función de una variedad de factores, como el clima, el suelo, las prácticas de manejo y las variedades de semillas. Esta información

puede ser utilizada para tomar decisiones informadas sobre la planificación de la siembra, el riego y la fertilización. (Kizil, S., & Turan, M., 2018)

### **Detección de plagas y enfermedades:**

Los sistemas de visión artificial basados en machine learning pueden ser utilizados para detectar plagas y enfermedades en los cultivos en tiempo real. Esta información puede ser utilizada para implementar medidas de control oportunas y prevenir pérdidas significativas de producción. (Monga, I., et al, 2016)

### **Optimización del riego:**

Los algoritmos de machine learning pueden ser utilizados para optimizar el riego de los cultivos en función de las condiciones climáticas y las necesidades de agua de las plantas. Esto puede ayudar a reducir el consumo de agua y mejorar la eficiencia del uso del agua. (Sibley, A. M., et al, 2016)

### **Análisis de suelos:**

Los sensores y los algoritmos de machine learning pueden ser utilizados para analizar las propiedades del suelo y proporcionar información sobre la fertilidad, la acidez y la salinidad del suelo. Esta información puede ser utilizada para aplicar los fertilizantes y enmiendas de suelo de manera más precisa y eficiente. (Sudarsan, A., & Blanchar, C., 2017)

### **Monitoreo del crecimiento de los cultivos:**

Los drones y los satélites equipados con sensores pueden ser utilizados para monitorear el crecimiento de los cultivos y detectar problemas potenciales. Esta información puede ser utilizada para tomar medidas correctivas de manera oportuna. (Atzberger, C., & Scheuermann, P., 2014)

### **Aumento de la productividad:**

El machine learning y la ciencia de datos pueden ayudar a aumentar la productividad de los cultivos mediante la predicción de rendimientos, la detección de plagas y enfermedades, y la optimización del riego y la fertilización. (FAO, 2019)

### **Reducción de costos:**

El machine learning y la ciencia de datos pueden ayudar a reducir los costos de producción mediante la optimización del uso de insumos, como el agua y los fertilizantes. (FAO, 2019)

Específicamente en el contexto de esta investigación el cual es el sector agrícola de Culiacán. El volumen de producción de maíz en Culiacán representa el 15.60% de todo el maíz producido en Sinaloa, como se puede observar en la Tabla 1. (CIEGSIN, 2023)

Municipio	Volumen de produccion estatal 2022(%)
Guasave	21.71%
Ahome	19.68%
Culiacan	15.60%
Navolato	13.35%
Angostura	9.83%

Tabla 1. Volumen de producción de maíz en Sinaloa por municipio. (CIEGSIN, 2023)

Por otro lado en la producción de tomate, Culiacán, representa el 26.38% del volumen de producción de tomate en Sinaloa, dicho esto se puede concluir que Culiacán es uno de los municipios productores más importantes de Sinaloa, como se puede observar en la Tabla 2. (CIEGSIN, 2023)



Municipio	Volumen de produccion estatal 2022(%)
Culiacan	26.38%
Navolato	21.64%
Escuinapa	10.96%
Elota	10.86%
Guasave	9.93%

Tabla 2. Volumen de producción de tomate en Sinaloa por municipio. (CIEGSIN, 2023)

En México se produjeron 22,046,099 toneladas de maíz grano, colocando a Sinaloa como el principal productor con 6.590,097 millones de toneladas esto en el año 2023. Por otro lado, en tomate se produjeron 3,220,048 toneladas; Sinaloa aportó 702,665 toneladas. Siendo así que este estado fue el productor más importante del país. (CIEGSIN, 2023)

Considerando los datos previos se puede inferir que el machine learning puede mejorar la producción de cultivos, concretamente el maíz y el tomate en Sinaloa.

Uno de los mayores retos en la producción del tomate son los nutrientes que estos necesitan para su crecimiento. El nitrógeno, fósforo y potasio son los nutrientes principales que se requieren para que el tomate crezca.

Las plantas de tomate tienen un indicativo de su estado de salud, si tiene una falta de nitrógeno las raíces se tornan de color amarillo. El color púrpura es un indicativo de una falta de fósforo. Por otro lado, si las raíces tienen manchas amarillas esto pasa por una falta de potasio, como se puede observar en la Figura 2. (Journal of Artificial Intelligence and Technology, 2021)



Fig. 2 - Ejemplos de las manchas en la planta del tomate (Journal of Artificial Intelligence and Technology, 2021)

Múltiples investigaciones indican que los nutrientes necesarios en la producción de tomate son deficientes, esto ha evocado que se dedique tiempo a buscar soluciones para que estos nutrientes no le hagan falta a los cultivos de tomate. Un ejemplo de ello son soluciones robóticas para el monitoreo de las plantas. Estos revisan el color de la planta con el fin de saber qué nutriente es lo que le hace falta.

(Journal of Artificial Intelligence and Technology, 2021)

La robótica ha revolucionado la agricultura, con aplicaciones en diversas tareas como la siembra, el cultivo, la fertilización, la supervisión y la cosecha. Ejemplos destacados incluyen el uso de tractores robotizados en Japón para grandes extensiones de terreno y salas controladas con robots y sensores que ajustan las condiciones ambientales para el cultivo de plantas. Además, la tecnología de visión ha mejorado la precisión en la detección de madurez y la calidad de los frutos, permitiendo un mejor manejo de la cosecha y la distribución. El aprendizaje profundo también se utiliza para monitorear la salud de las plantas, detectando deficiencias nutricionales y plagas, lo que contribuye a una producción más eficiente y de mayor calidad. (Journal of Artificial Intelligence and Technology, 2021)



Fig. 3- Ejemplo de robots móviles en forma de tractores.

### **Manejo de malezas:**

El uso de machine learning para el manejo de malezas está ganando tracción. Sistemas de visión artificial pueden identificar y clasificar malezas en tiempo real, lo que permite la aplicación selectiva de herbicidas y reduce el uso de químicos, beneficiando tanto al medio ambiente como a la economía de los agricultores (Johnson, Mortensen, & Jabbour, 2019). Estos sistemas utilizan cámaras y sensores para capturar imágenes de los campos, las cuales son analizadas por algoritmos de machine learning para diferenciar entre cultivos y malezas. Esta precisión permite una aplicación más eficiente de herbicidas, disminuyendo la cantidad de químicos necesarios y, por ende, reduciendo la contaminación y el costo de producción. (Johnson, W. G., et al, 2019)

## Mejora en la cadena de suministro:

El machine learning también puede optimizar la cadena de suministro agrícola. Algoritmos avanzados pueden predecir la demanda de productos agrícolas, optimizar rutas de distribución y minimizar desperdicios. Esto asegura que los productos lleguen frescos al mercado y reduce las pérdidas post-cosecha. Por ejemplo, los modelos predictivos pueden utilizar datos históricos y en tiempo real para anticipar la demanda, ajustando la producción y distribución en consecuencia. Esto no solo mejora la eficiencia, sino que también ayuda a reducir el impacto ambiental asociado con el transporte y almacenamiento innecesario.

(Kamilaris, Kartakoullis, & Prenafeta-Boldú, 2017)



Fig. 4- Imagen ilustrativa de las mejoras en la cadena de suministros en la agricultura con el uso de la IA y el machine learning.

## Adaptación al cambio climático:

El cambio climático es una amenaza creciente para la agricultura. Los modelos predictivos basados en machine learning pueden ayudar a los agricultores a adaptarse a condiciones climáticas cambiantes. Por ejemplo, pueden prever periodos de sequía o excesos de lluvia, permitiendo la implementación de medidas

preventivas para proteger los cultivos. Estos modelos pueden integrar datos climáticos históricos con predicciones meteorológicas para asesorar sobre las mejores prácticas de riego, selección de cultivos y planificación de la siembra. (Lobell, Schlenker, & Costa-Roberts, 2011).

### **Automatización de maquinaria agrícola:**

La automatización mediante machine learning no se limita a la robótica tradicional. Tractores autónomos y cosechadoras equipadas con sistemas de aprendizaje automático pueden operar de manera más eficiente, reduciendo costos de mano de obra y mejorando la precisión en la siembra y cosecha. Estos sistemas pueden ajustar automáticamente la velocidad, la profundidad de siembra y la recolección en función de las condiciones del terreno y del cultivo, mejorando así la eficiencia y reduciendo el desperdicio. (Shamshiri et al., 2018)

### **Predicción de calidad de cultivos:**

Más allá de la cantidad, la calidad de los cultivos es crucial. Los algoritmos de machine learning pueden analizar imágenes y datos sensoriales para prever la calidad de la cosecha, ayudando a los agricultores a mejorar prácticas de manejo y post-cosecha. Estos análisis pueden identificar problemas como plagas, enfermedades o deficiencias nutricionales en etapas tempranas, permitiendo intervenciones oportunas que mejoren la calidad final del producto. (Pantazi, Moshou, Alexandridis, Whetton, & Mouazen, 2016)

### **Detección de estrés hídrico:**

El estrés hídrico es un problema común que afecta la producción agrícola. Utilizando imágenes de satélite y datos de sensores, los algoritmos de machine learning

pueden detectar signos de estrés hídrico en las plantas, permitiendo intervenciones rápidas para mitigar el impacto. Estos sistemas pueden medir variables como la temperatura del suelo y la humedad, proporcionando datos precisos que ayudan a optimizar el uso del agua y prevenir daños por sequía. (Hassan-Esfahani, Torres-Rua, Jensen, & McKee, 2015)

### **Desarrollo de nuevas variedades de cultivos:**

El análisis de grandes volúmenes de datos genéticos mediante machine learning puede acelerar el desarrollo de nuevas variedades de cultivos que sean más resistentes a enfermedades, plagas y condiciones climáticas adversas, optimizando así la producción agrícola. Al identificar patrones en los datos genómicos, los investigadores pueden seleccionar características deseables de manera más eficiente, reduciendo el tiempo y el costo asociados con los métodos tradicionales de mejoramiento genético. (Crossa et al., 2017)

## **METODOLOGÍA**

Para el desarrollo de este proyecto, se seguirá un enfoque basado en el uso de herramientas de inteligencia artificial, machine learning y análisis de Big Data aplicadas a la agricultura sostenible. La metodología se divide en tres etapas clave:

### **Fase 1. Recolección y Procesamiento de Datos**

Se recopilarán datos agrícolas de diversas fuentes, como sensores en el campo, imágenes satelitales, datos meteorológicos e información histórica de cultivos. Estos datos serán procesados y limpiados utilizando herramientas de Big Data para garantizar su calidad y utilidad en el entrenamiento de modelos de IA.

## **Fase 2. Desarrollo e Implementación de Modelos de IA y Machine Learning**

Se entrenarán modelos de Machine Learning para predecir el rendimiento de cultivos, detectar plagas y optimizar el uso de recursos como agua y fertilizantes. Estos modelos serán integrados en sistemas de apoyo a la decisión para los agricultores.

## **Fase 3. Validación y Optimización**

Los modelos serán probados en entornos reales para medir su efectividad y optimizados en función de los resultados obtenidos. Se buscará mejorar la precisión de las predicciones y facilitar la implementación práctica en el sector agrícola.

### **PROGRAMA DE ACTIVIDADES Y CALENDARIZACIÓN**

<b>Actividad</b>	<b>Duración</b>
Recolección de datos	3 meses
Desarrollo de modelos	4 meses
Pruebas en campo	3 meses
Evaluación de resultados	2 meses

## **VINCULACIÓN**

Este proyecto se realizará en colaboración con agricultores locales, instituciones académicas y empresas tecnológicas para garantizar una implementación efectiva y el desarrollo de soluciones aplicables a gran escala.



## REFERENCIAS

- Benos, L., Tagarakis, A. C., Dolias, G., Berruto, R., Kateris, D., & Bochtis, D. (2021). Machine Learning in Agriculture: A Comprehensive Updated Review. *Sensors*, 21(11), 3758.
- Mourtzinis, S., Esker, P. D., Specht, J. E., & Conley, S. P. (2021b). Advancing agricultural research using machine learning algorithms. *Scientific Reports*, 11(1).
- Singh, A. (2019). Big Data in Agricultural Research and Development. *National Academy of Agricultural Sciences*, 3-5.
- Cravero, A., Pardo, S., Sepúlveda, S., & Muñoz, L. (2022). Challenges to Use Machine Learning in Agricultural Big Data: A Systematic Literature Review. *Agronomy*, 12(3), 748.
- Araújo, S. O., Peres, R. S., Ramalho, J. C., Lidon, F. C., & Barata, J. (2023). Machine Learning Applications in Agriculture: Current Trends, Challenges, and Future Perspectives. *Agronomy*, 13(12), 2976.
- Ben-Ayed, H., Kamoun-Grati, H., & Rebai, A. (2013). Food Safety Incidents and Food Traceability: A Review. *Journal of Food Protection*, 76(3), 439-447.
- Kizil, S., & Turan, M. (2018). Machine learning for crop yield prediction: A comprehensive overview. *Artificial Intelligence for Agriculture*, 1(2), 8-29. (<https://www.sciencedirect.com/science/article/pii/S0168169920302301>)
- Monga, I., Sy, J. D., Saxena, A., & Mani, K. V. (2016). A review of smart pest and disease detection in precision agriculture. *Computers and Electronics in Agriculture*, 127, 86-93. (<https://www.mdpi.com/2077-0472/10/5/161>)
- Sibley, A. M., Grassini, P., & Lobell, D. B. (2016). Remote sensing for crop yield prediction and management. In *Precision Agriculture through Sensor Networks* (pp.

3-34). Springer, Cham.  
(<https://www.sciencedirect.com/science/article/pii/S1110982322000527>)

Sudarsan, A., & Blanchar, C. (2017). Soil properties estimation using machine learning and satellite imagery. In Proceedings of the 33rd Annual ACM Conference on International Conference on Information and Knowledge Management (pp. 2187-2190). ACM.  
(<https://www.mdpi.com/2073-445X/12/2/494>)

Atzberger, C., & Scheuermann, P. (2014). Proximal sensing of evapotranspiration for water management in agriculture. In Remote Sensing of Water Resources (pp. 163-184). Springer, Dordrecht.  
([https://www.researchgate.net/publication/221919364\\_Evapotranspiration\\_and\\_Water\\_Management\\_for\\_Crop\\_Production](https://www.researchgate.net/publication/221919364_Evapotranspiration_and_Water_Management_for_Crop_Production))

Food and Agriculture Organization of the United Nations (FAO). (2019). The State of Food Security and Nutrition in the World 2019: Transforming food systems for eradicating hunger, malnutrition and achieving food security. FAO.  
(<https://www.fao.org/3/ca5162en/ca5162en.pdf>)

Centro de Información, Estadística y Geografía del Estado de Sinaloa (CIEGSIN) (2023). Agricultura.  
(<https://estadisticas.sinaloa.gob.mx/eBooks/Temas/AGRICULTURA2023.pdf>)

Centro de Información, Estadística y Geografía del Estado de Sinaloa (CIEGSIN) (2023). Sinaloa es primero. ([https://estadisticas.sinaloa.gob.mx/EE\\_Sinaloav2.aspx](https://estadisticas.sinaloa.gob.mx/EE_Sinaloav2.aspx))

Journal of Artificial Intelligence and Technology (2021). Estimation of Low Nutrients in Tomato Crops Through the Analysis of Leaf Images Using Machine Learning. (<https://ojs.istp-press.com/jait/article/view/19/25>)

Johnson, W. G., Mortensen, D. A., & Jabbour, R. (2019). Weed research: Expanding horizons in herbicide resistance, weed ecology, and technology. *Weed Science*, 67(sp1), 70-84. <https://doi.org/10.1017/wsc.2018.86>

Kamilaris, A., Kartakoullis, A., & Prenafeta-Boldú, F. X. (2017). A review on the practice of big data analysis in agriculture. *Computers and Electronics in Agriculture*, 143, 23-37. <https://doi.org/10.1016/j.compag.2017.09.037>

Lobell, D. B., Schlenker, W., & Costa-Roberts, J. (2011). Climate trends and global crop production since 1980. *Science*, 333(6042), 616-620. <https://doi.org/10.1126/science.1204531>